AI Safety Challenge

Çıktı: AI Fail-Safe Decision | EP 03 + EP 15

Ad Soyad: Hüseyin Enes Ertürk **Grup:** Yazılım Gece B **Tarih: 06.11.2026**

Bu makinede kamera veya yapay zekâ kullanıldığı doğrulanmadı. Föyü uyarlamak için kesilecek malzemeyi kamerayla OK/RED olarak değerlendiren yardımcı bir sistem varsayıyorum. Yapay zekâ kararı insanı koruyan emniyet işlevlerinin yerine geçmez.

Bu makine için varsayılan yardımcı yapay zekâ akışı

Kamera / girdi bütünlük kontrolü → **Yapay zekâ önerisi OK / RED + skor** → **Bağımsız kontrol + yerel teyit** → **Normal PLC çevrim isteği**

Emniyet yolu ayrı kalır: kapak / şerit duruşu + güvenli tutma + yerel yeniden başlatma

Görev - üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: kusurlu parçaya OK verdi. Sistem ne yapmalı?

OK sonucu tek başına kesimi başlatmamalıdır. Operatör ve bağımsız ölçü/bağlama kontrolüyle malzeme tekrar kontrol edilmelidir. Şüpheli durumda sonraki kesim engellenir; tehlikeli hareket varsa güvenli duruş sağlanır. İnsan onayı, kapak ve diğer emniyet korumalarını devre dışı bırakamaz.

2. Girdi manipüle edildi: kamera verisi bozuk/sahte. Nasıl fark edilir, ne yapılır?

Görüntünün kaynağı ve zamanı, donmuş veya bulanık olup olmadığı ve diğer ölçümlerle uyumu kontrol edilir. Şüpheli görüntüyle karar verilmez; yeni kesim bekletilir ve operatör inceleme yapar. Bu kontroller her sahte girdiyi yakalayamayacağı için emniyet yolu bağımsız kalmalıdır.

3. Confidence düştü: eşik ne olmalı? Altında ne yapılır?

Güven eşiği, gerçek kullanım koşullarını temsil eden testlerle belirlenmelidir. Veri olmadığı için rastgele bir sayı vermiyorum. Eşik belirlenene kadar otomatik kabul yapılmaz. Eşik altında veya skor yoksa sistem güvenli biçimde bekler ve operatöre sorar. Gerekirse yapay zekâ olmadan, önceden güvenliği doğrulanmış yerel çalışma düzenine dönülür.

Karar tablosu - AI Fail-Safe Decision

Başarısızlık	Tanımlanan güvenli davranış ve kullanılan kavram
Model yanlış sınıflandırdı	İkinci kontrol ve insan onayı. Human override: insan yapay zekâ kararını iptal eder; emniyet korumasını aşmaz.
Girdi manipüle edildi	Monitoring: görüntü ve diğer ölçümler izlenir. Fail-safe: şüphede yeni kesim engellenir, sistem güvenli bekler.
Confidence düştü	Confidence threshold: doğrulanmış eşik altında kabul yok. Fallback: yalnız güvenliği doğrulanmış yerel düzene dönülür; bu mümkün değilse beklenir.