AI Safety Challenge

Çıktı: AI Fail-Safe Decision | EP 03 + EP 15

Ad Soyad: **Grup:** **Tarih: 06.11.2026**

[B] K1'de YZ/kamera sistemi doğrulanmıyor. [V] Kesilecek malzemeyi kamerayla OK/RED sınıflandıran yardımcı YZ eklendiğini varsayıyoruz. Mevcut makine özelliği değildir; YZ tahmini emniyet garantisi vermez [F1].

[D] Kaynakta doğrulanan | [B] Bilinmiyor | [V] Varsayım | [Ö] Öneri | [Ç] Analitik çıkarım

Varsayımsal yardımcı YZ yolu [V] / önerilen sınırlar [Ö]



Emniyet yolu YZ dışında: kapak / şerit duruşu + güvenli tutma + yerel yeniden başlatma [Ö]

Görev - üç başarısızlıkta güvenli davranış

1. Model kusurlu malzemeye OK verdi: ne yapılır?

[V] Eğri/uygunsuz malzemeyi kabul etmek, hatalı bağlama koşuluyla birleşirse şerit sıkışmasına veya parça fırlamasına yol açabilir. [Ö] OK tek başına kesim başlatmaz; yerel operatör ve bağımsız ölçü/bağlama kontrolü gerekir. Şüphede sonraki çevrim engellenir, hareket varsa doğrulanmış duruş uygulanır. Kör örneklem kontrolü ve hatalı OK takibi yapılır; yüksek güvenli tahmin de yanlış olabilir.

2. Kamera girdisi bozuk/sahte: nasıl fark edilir, ne yapılır?

[Ö] Kaynak kimliği/bütünlüğü, kare zaman damgası ve sıra bilgisi, donmuş görüntü, bulanıklık ve bağımsız sensör tutarlılığı izlenir. Geçersiz veya eski karede YZ önerisi reddedilir, alarm ve kanıt kaydı üretilir; güvenli bekleme ve yerel inceleme gerekir. Bu kontroller tüm manipülasyonları yakalama garantisi vermez. Kayıtlı eski OK sonucu kullanılmaz.

3. Confidence düştü: eşik ve eşik altı davranış?

[Ö] Güven eşiği tau, temsilî doğrulama verisinde hatalı OK oranı ve fiziksel risk dikkate alınarak belirlenmeli; model skoru tek başına doğruluk olasılığı sayılmaz. [B] Veri/kalibrasyon olmadığı için sayısal eşik atanmadı; belirlenene kadar otomatik kabul kapalı. Eşik altında, eksik/geçersiz skorda veya dağılım dışı girdide çevrim izni verilmez; alarm, yerel insan incelemesi ve doğrulanmış fallback uygulanır [K12].

Karar tablosu - AI Fail-Safe Decision [Ö]

Başarısızlık	Tanımlanan güvenli davranış	Kavram
Yanlış OK	Bağımsız kontrol ve yerel onay; tehlikeli çevrimi engelle.	Human override / monitoring
Manipüle girdi	Geçersiz öneriyi reddet; güvenli bekle, incele ve kaydet.	Fail-safe / monitoring
Düşük confidence	Otomatik kabul yok; yerel incelemeye geç. Son OK'yi kullanma.	Confidence threshold / fallback

Bağımsız emniyet ve kabul ölçütü

[Ö] YZ/iletişim arızası; kapak/şerit duruşunu, yük tutmayı veya yerel yeniden başlatma şartını devre dışı bırakamamalı. Human override yalnız YZ önerisini iptal eder; emniyet kilidini aşmaz. Fallback, YZ'siz ve risk değerlendirmesiyle doğrulanmış yerel işletimdir; bu koşul yoksa güvenli bekleme sürer. Üç hata sınıfı, yüksek güvenli yanlış OK ve YZ kapalı durumu ayrı test edilmeden kullanım onayı verilmez [K5, K12].

EP 03 + EP 15 - kaydedilecek kanıt

[Ö] Model/veri sürümü, girdi zamanı ve bütünlük sonucu, skor/eşik, karar ve gerekçesi, yerel onay, emniyet tepkisi ve test sonucu kaydedilir. Eşik ve algılama süreleri ölçümle doğrulanacak açık gereksinimlerdir. Durum: kavramsal karar tablosu hazır; model geliştirme, performans ölçümü ve gerçek makine testi yapılmadı.

Öneri, NIST AI RMF rehberindeki güvenli hata/izleme yaklaşımıyla ilişkilidir; emniyet sertifikası iddiası içermez.

[F1] Dersin Lab Föyleri PDF dosyası, s. 8 (yerel) | [K1] Karmetal ürün sayfası | [K5] NIST SP 800-82 Rev.3 | [K12] NIST AI RMF 1.0 | Bağlantılar tıklanabilir; kaynak/kanıt kaydı: docs/KAYNAKLAR.md. Erişim: 06.11.2026.